

# Projet BDD - Optimisation des Requêtes SQL

---

Julien TAP  
ET4 - IIM - Groupe1

---

## Table des Matières

---

### Introduction

---

### Exercice 1

#### Partie 1

##### Question 1

Création des deux tables CLIENTS et OCCUPATION avec les instructions SQL suivantes :

```
CREATE TABLE CLIENT
(
CLI_ID INTEGER ,
TIT_CODE VARCHAR (10) ,
CLI_NOM VARCHAR (30) ,
CLI_PRENOM VARCHAR (30) ,
CLI_ENSEIGNE VARCHAR (50)
);

CREATE TABLE OCCUPATION
(
CHB_ID INTEGER ,
JOUR VARCHAR (10) ,
CLI_ID INTEGER ,
NB_PERS INTEGER ,
RESERVE INTEGER
);
```

##### Question 2

Peuplement des tables CLIENTS et OCCUPATION avec les instructions SQL présentes dans le fichier [fillBaseHotel.sql](#).

##### Question 3

Expression des requêtes SQL demandées:

1. Le nom et prénom du client numéro 5

```
SELECT CLI_NOM, CLI_PRENOM  
FROM client  
WHERE CLI_ID =5;
```

2. Les jours où le client numéro 5 a occupé une chambre

```
SELECT JOUR  
FROM OCCUPATION  
WHERE CLI_ID = 5;
```

3. Les chambres occupées le 1999-01-22

```
SELECT CHB_ID  
FROM OCCUPATION  
WHERE JOUR = '1999-01-22';
```

4. Le nom et prénom des clients ayant pris une chambre le 1999-01-22

```
SELECT CLI_NOM, CLI_PRENOM  
FROM CLIENT, OCCUPATION  
WHERE CLIENT.CLI_ID = OCCUPATION.CLI_ID  
AND OCCUPATION.JOUR = '1999-01-22';
```

#### Question 4

Pour chacune des requêtes précédentes, on donne maintenant le plan d'exécution obtenu avec EXPLAIN, on interprète ce résultat, puis on dessine ce plan sous forme d'arbre.

1. Le nom et prénom du client numéro 5

```
EXPLAIN SELECT CLI_NOM, CLI_PRENOM  
FROM client  
WHERE CLI_ID =5;
```

QUERY PLAN

```
Seq Scan on client  (cost=0.00..2.25 rows=1 width=15)  
  Filter: (cli_id = 5)  
(2 rows)
```

On voit que le plan d'exécution utilise un "Seq Scan" (parcours séquentiel) sur la table client, ce qui signifie que chaque ligne de la table est examinée pour trouver celles qui correspondent à la condition CLI\_ID = 5. Le coût estimé de cette opération est de 0.00 à 2.25, avec une estimation de 1 ligne retournée.

Seq Scan  
on client

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General IO & Buffers Output Workers Misc

⌚ **Timing:** -  
☰ **Rows:** N/A (Planned: 1)  
\$LANG\$ **Cost:** **2.25** (Total: 2.25)

2. Les jours où le client numéro 5 a occupé une chambre

```
EXPLAIN SELECT JOUR
FROM OCCUPATION
WHERE CLI_ID = 5;
```

QUERY PLAN

```
-----  
Seq Scan on occupation  (cost=0.00..361.27 rows=166 width=11)
  Filter: (cli_id = 5)
(2 rows)
```

On voit que le plan d'exécution utilise également un "Seq Scan" sur la table OCCUPATION pour trouver les enregistrements où CLI\_ID = 5. Le coût estimé est de 0.00 à 361.27, avec une estimation de 166 lignes retournées.

## Seq Scan

\$ #1

on occupation

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General IO & Buffers Output Workers Misc

⌚ **Timing:** -

☰ **Rows:** N/A (Planned: 166)

\$ **Cost:** **361.27** (Total: 361.27)

### 3. Les chambres occupées le 1999-01-22

```
EXPLAIN SELECT CHB_ID  
FROM OCCUPATION  
WHERE JOUR = '1999-01-22';
```

#### QUERY PLAN

```
-----  
Seq Scan on occupation  (cost=0.00..361.27 rows=11 width=4)  
    Filter: ((jour)::text = '1999-01-22'::text)  
(2 rows)
```

On voit que le plan d'exécution utilise encore un "Seq Scan" sur la table OCCUPATION pour trouver les enregistrements où JOUR = '1999-01-22'. Le coût estimé est de 0.00 à 361.27, avec une estimation de 11 lignes retournées.

## Seq Scan

\$ #1

on occupation

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General

IO & Buffers

Output

Workers

Misc

⌚ **Timing:** -

☰ **Rows:** N/A (Planned: 11)

💲 **Cost:** **361.27** (Total: 361.27)

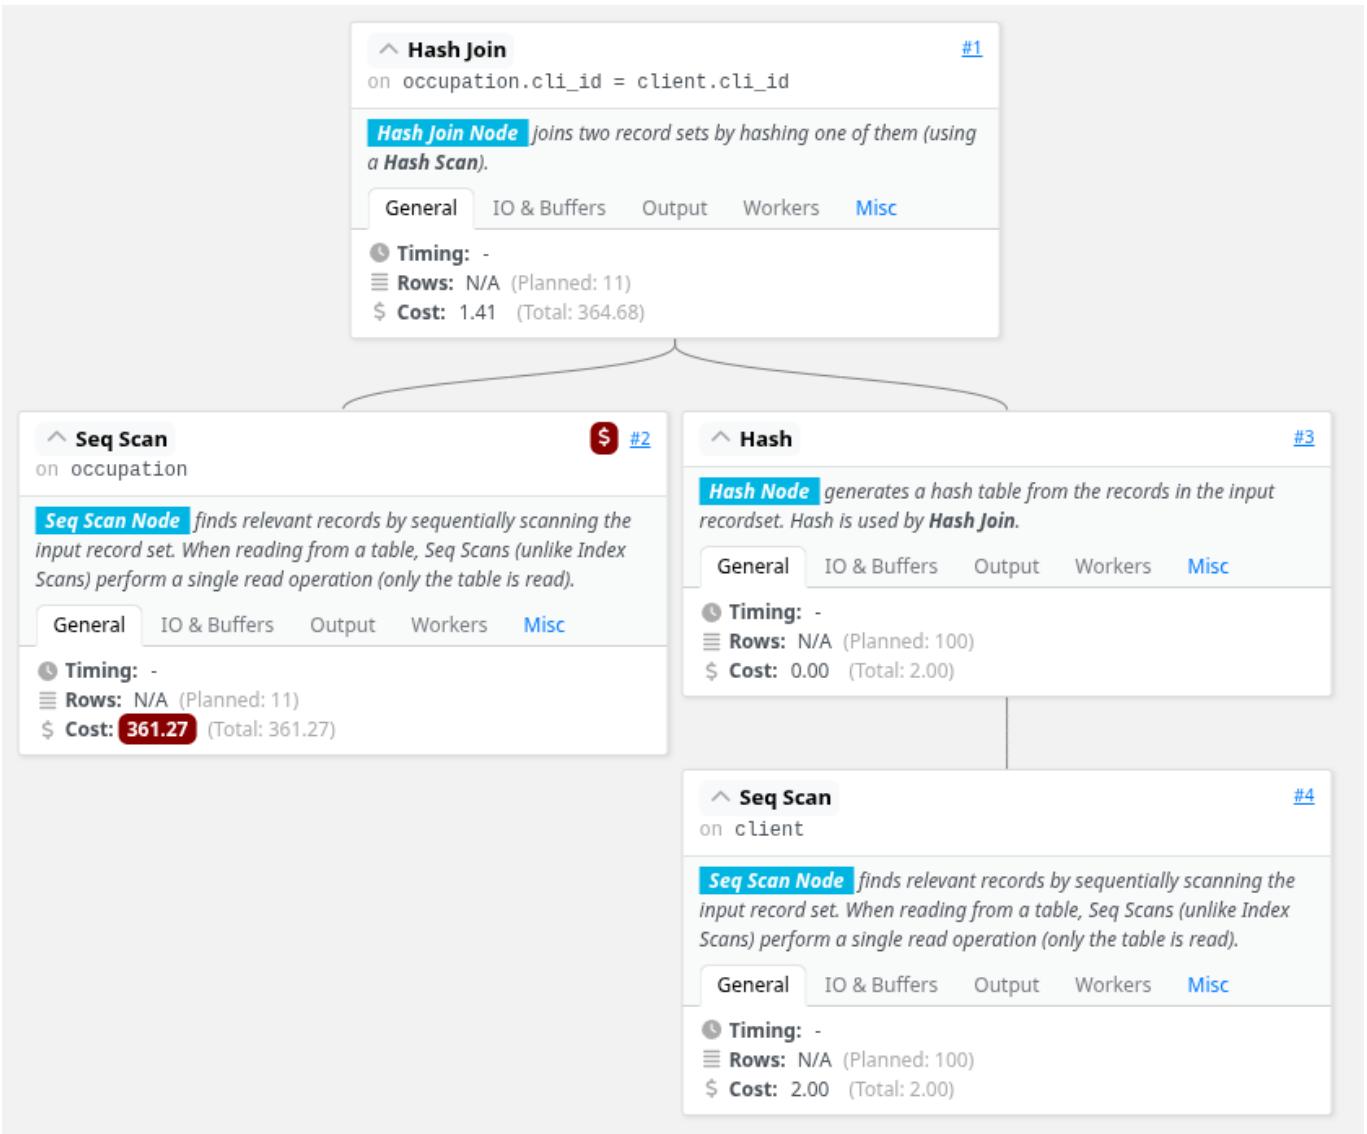
4. Le nom et prénom des clients ayant pris une chambre le 1999-01-22

```
EXPLAIN SELECT CLI_NOM, CLI_PRENOM  
FROM CLIENT, OCCUPATION  
WHERE CLIENT.CLI_ID = OCCUPATION.CLI_ID  
AND OCCUPATION.JOUR = '1999-01-22';
```

QUERY PLAN

```
Hash Join (cost=3.25..364.68 rows=11 width=15)  
  Hash Cond: (occupation.cli_id = client.cli_id)  
    -> Seq Scan on occupation (cost=0.00..361.27 rows=11 width=4)  
        Filter: ((jour)::text = '1999-01-22'::text)  
    -> Hash (cost=2.00..2.00 rows=100 width=19)  
        -> Seq Scan on client (cost=0.00..2.00 rows=100 width=19)  
(6 rows)
```

Le plan d'exécution utilise un "Hash Join" pour combiner les tables CLIENT et OCCUPATION en fonction de la condition de jointure. La table OCCUPATION est parcourue séquentiellement pour trouver les enregistrements où JOUR = '1999-01-22', puis une table de hachage est créée à partir de la table CLIENT pour effectuer la jointure. Le coût estimé est de 3.25 à 364.68, avec une estimation de 11 lignes retournées.



## Partie 2

### Question 1

On veut maintenant optimiser les requêtes précédentes en créant des index appropriés sur CLIENT.CLI\_ID, OCCUPATION.CLI\_ID et OCCUPATION.JOUR.

```

CREATE UNIQUE INDEX idx_client_cli_id ON CLIENT(CLIENT_ID);
CREATE INDEX idx_occupation_cli_id ON OCCUPATION(CLIENT_ID);
CREATE INDEX idx_occupation_jour ON OCCUPATION(JOUR);

```

L'index 'idx\_client\_cli\_id' est le seul index unique, car CLIENT\_ID dans la table CLIENT est une clé primaire et doit être unique pour chaque client. Les autres index sont non uniques, car plusieurs enregistrements dans la table OCCUPATION peuvent partager les mêmes valeurs pour CLIENT\_ID ou JOUR.

### Question 2

On réexécute les requêtes précédentes avec EXPLAIN pour observer les changements dans les plans d'exécution après la création des index.

## 1. Le nom et prénom du client numéro 5

```
EXPLAIN SELECT CLI_NOM, CLI_PRENOM  
FROM client  
WHERE CLI_ID =5;
```

### QUERY PLAN

```
Seq Scan on client  (cost=0.00..2.25 rows=1 width=15)  
  Filter: (cli_id = 5)  
(2 rows)
```

On constate que le plan d'exécution reste un "Seq Scan" sur la table client, ce qui indique que l'index n'a pas été utilisé pour cette requête. Cela peut être dû au fait que la table CLIENT est relativement petite, et le système de gestion de base de données a estimé qu'un parcours séquentiel serait plus efficace que l'utilisation de l'index.

The screenshot shows a detailed view of a query execution plan node. At the top, it says "Seq Scan" with a back arrow icon and a red button with a dollar sign and "#1". Below that, it says "on client". A descriptive text box contains the following text: "Seq Scan Node finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read)." Below this, there are tabs for "General", "IO & Buffers", "Output", "Workers", and "Misc". The "Misc" tab is currently selected. Under "Misc", there are two entries: "Timing: -" and "Rows: N/A (Planned: 1)". The "Cost" entry is highlighted with a red box and shows "2.25 (Total: 2.25)".

## 2. Les jours où le client numéro 5 a occupé une chambre

```
EXPLAIN SELECT JOUR  
FROM OCCUPATION  
WHERE CLI_ID = 5;
```

### QUERY PLAN

```
Bitmap Heap Scan on occupation  (cost=5.57..148.74 rows=166 width=11)  
  Recheck Cond: (cli_id = 5)  
    -> Bitmap Index Scan on idx_occupation_cli_id  (cost=0.00..5.53  
rows=166 width=0)  
          Index Cond: (cli_id = 5)  
(4 rows)
```

On voit que le plan d'exécution utilise maintenant un "Bitmap Heap Scan" sur la table OCCUPATION, ce qui indique que l'index 'idx\_occupation\_cli\_id' a été utilisé pour trouver les enregistrements où CLI\_ID = 5. Le coût estimé est de 5.57 à 148.74, avec une estimation de 166 lignes retournées.

^ **Bitmap Heap Scan** \$ #1

on occupation

**Bitmap Heap Scan Node** searches through the pages returned by the **Bitmap Index Scan** for relevant rows.

General IO & Buffers Output Workers Misc

⌚ **Timing:** -

☰ **Rows:** N/A (Planned: 166)

\$ **Cost:** 143.21 (Total: 148.74)

^ **Bitmap Index Scan** #2

using idx\_occupation\_cli\_id

**Bitmap Index Scan Node** uses a **Bitmap Index** (index which uses 1 bit per page) to find all relevant pages. Results of this node are fed to the **Bitmap Heap Scan**.

General IO & Buffers Output Workers Misc

⌚ **Timing:** -

☰ **Rows:** N/A (Planned: 166)

\$ **Cost:** 5.53 (Total: 5.53)

### 3. Les chambres occupées le 1999-01-22

```
EXPLAIN SELECT CHB_ID
FROM OCCUPATION
WHERE JOUR = '1999-01-22';
```

#### QUERY PLAN

```
-----
Index Scan using idx_occupation_jour on occupation (cost=0.29..25.44
rows=11 width=4)
  Index Cond: ((jour)::text = '1999-01-22'::text)
(2 rows)
```

On voit que le plan d'exécution utilise un "Index Scan" sur la table OCCUPATION, ce qui indique que l'index 'idx\_occupation\_jour' a été utilisé pour trouver les enregistrements où JOUR = '1999-01-22'. Le coût estimé est de 0.29 à 25.44, avec une estimation de 11 lignes retournées.

Index Scan

on occupation  
using idx\_occupation\_jour

**Index Scan Node** finds relevant records based on an **Index**. Index Scans perform 2 read operations: one to read the index and another to read the actual value from the table.

General IO & Buffers Output Workers Misc

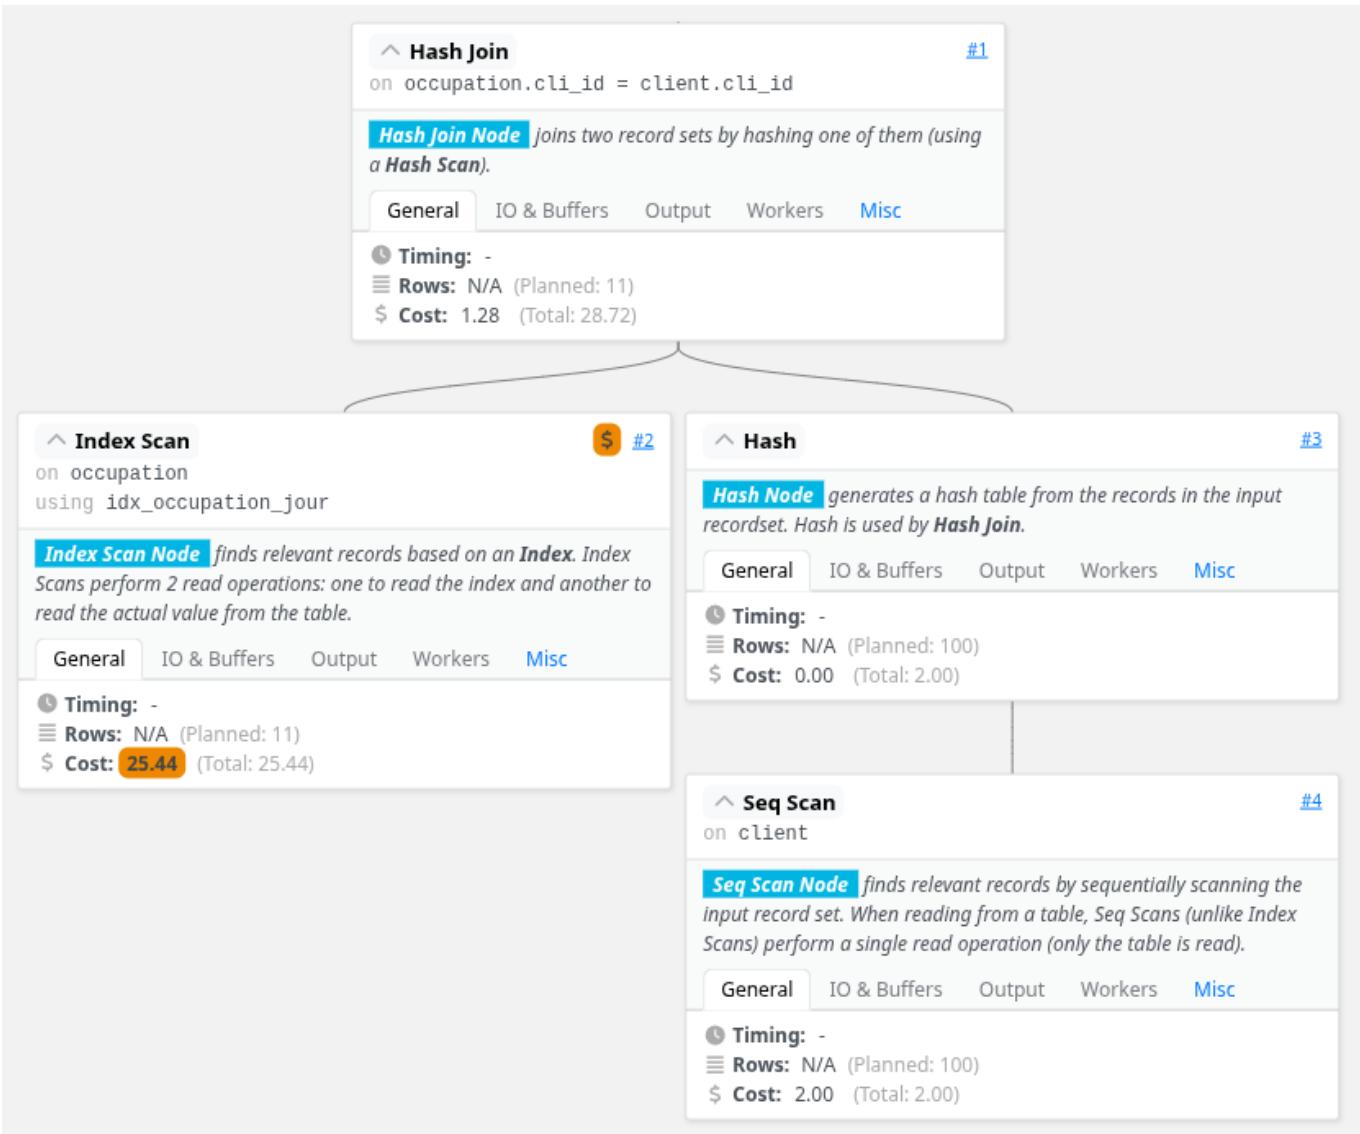
⌚ **Timing:** -  
☰ **Rows:** N/A (Planned: 11)  
\$LANG\$ **Cost:** **25.44** (Total: 25.44)

4. Le nom et prénom des clients ayant pris une chambre le 1999-01-22

```
EXPLAIN SELECT CLI_NOM, CLI_PRENOM
FROM CLIENT, OCCUPATION
WHERE CLIENT.CLI_ID = OCCUPATION.CLI_ID
AND OCCUPATION.JOUR = '1999-01-22';

QUERY PLAN
-----
Hash Join  (cost=3.54..28.72 rows=11 width=15)
  Hash Cond: (occupation.cli_id = client.cli_id)
    -> Index Scan using idx_occupation_jour on occupation
       (cost=0.29..25.44 rows=11 width=4)
          Index Cond: ((jour)::text = '1999-01-22'::text)
    -> Hash  (cost=2.00..2.00 rows=100 width=19)
          -> Seq Scan on client  (cost=0.00..2.00 rows=100 width=19)
(6 rows)
```

Le plan d'exécution utilise toujours un "Hash Join" pour combiner les tables CLIENT et OCCUPATION, mais cette fois-ci, l'index 'idx\_occupation\_jour' est utilisé pour accéder aux enregistrements de la table OCCUPATION. Le coût estimé est de 3.54 à 28.72, avec une estimation de 11 lignes retournées.



## Partie 3

### Question 1

On récupère les statistiques sur les tables avec less commandes suivantes :

```

ANALYSE CLIENT , OCCUPATION;

ANALYSE VERBOSE CLIENT , OCCUPATION;

INFO: analyzing "public.client"
INFO: "client": scanned 1 of 1 pages, containing 100 live rows and 0 dead
rows; 100 rows in sample, 100 estimated total rows
INFO: finished analyzing table "hotels.public.client"
avg read rate: 15.625 MB/s, avg write rate: 0.000 MB/s
buffer usage: 42 hits, 2 reads, 0 dirtied
WAL usage: 9 records, 0 full page images, 1332 bytes, 0 buffers full
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s
INFO: analyzing "public.occupation"
INFO: "occupation": scanned 134 of 134 pages, containing 18182 live rows
and 0 dead rows; 18182 rows in sample, 18182 estimated total rows
  
```

```
INFO: finished analyzing table "hotels.public.occupation"
avg read rate: 0.000 MB/s, avg write rate: 0.000 MB/s
buffer usage: 170 hits, 0 reads, 0 dirtied
WAL usage: 7 records, 0 full page images, 500 bytes, 0 buffers full
system usage: CPU: user: 0.02 s, system: 0.00 s, elapsed: 0.02 s
```

Les plans d'exécution des requêtes ne changent pas après l'analyse des tables, car les statistiques collectées n'ont pas modifié les estimations de coût ou de cardinalité utilisées par le planificateur de requêtes.

## Exercice 2

### Partie 1

Cette première partie consiste à mettre en place les tables et les index nécessaires pour exécuter les requêtes demandées.

#### Question 1

On commence par créer les tables avec les instructions SQL suivantes :

```
drop schema if exists optimisation cascade;
create schema optimisation;
set search_path to optimisation ;
--drop table if exists clients cascade;
create unlogged table clients(
NumC integer primary key ,
NomC varchar (35),
AdresseC text
);
--drop table if exists produits cascade;
create unlogged table produits(
NumP integer primary key ,
NomP varchar (35),
descriptif text
);
--drop table if exists commandes cascade;
create unlogged table commandes(
DateCom date ,
NumC integer ,
Commentaire text ,
primary key(DateCom ,NumC)
);
--drop table if exists livraisons ;
create unlogged table livraisons(
DateLiv date ,
DateCom date ,
NumC Integer ,
Prestataire varchar ,
primary key(DateLiv ,DateCom ,NumC)
);
```

```
--drop table if exists Concerne;
create unlogged table concerne(
NumP integer ,
DateCom date ,
NumC integer ,
Quantite integer ,
primary key (NumP ,DateCom ,NumC)
);
```

## Question 2

Il nous faut ensuite executer le script qui implémente une génération aléatoire de tuples afin de tester les performances des charges de travail future

```
drop procedure if exists rempli_tables;
create procedure rempli_tables(nbtuples integer)
as $$
declare
k integer;
un_numP integer;
compt integer;
une_date date;
curs_com cursor for select DateCom , numc
from optimisation.commandes;
begin
INSERT INTO optimisation.clients (numc , nomc , adressec)
SELECT g, 'nomc_'||( random () * nbtuples * 4 / 5):: integer)::varchar ,
md5(g::text)
||md5 ((2*g)::text)||md5 ((3*g)::text)
FROM generate_series (0,nbtuples -1) as g;
INSERT INTO optimisation.produits (nump , nomp , descriptif)
SELECT g, 'nomp_'||( random () * nbtuples * 4 / 5):: integer)::varchar ,
md5(g::text)
||md5 ((2*g)::text)||md5 ((3*g)::text)
FROM generate_series (0,nbtuples -1) as g;
for g in 1..4*( nbtuples -1) loop
une_date = CURRENT_TIMESTAMP - (( random () * 3650):: integer ||'day')::
interval;
un_numP =( random ()*(nbtuples -1)):: integer;
insert into optimisation.commandes (DateCom , numc , commentaire)
select une_date , un_numP , md5(g::text)||md5 ((2*g)::text)||md5 ((3*
g)::text) on conflict do nothing;
end loop;
for t in curs_com
loop
k=( random () *6):: integer;
for i in 1..k loop
un_numP = (random ()*(nbtuples -1)):: integer;
insert into optimisation.concerne (NumP ,datecom ,numc ,
quantite)
values (un_numP ,t.Datecom ,t.numc ,( random ()*100):: integer)
```

```

on conflict do nothing;
if i>3 then
une_date = t.datecom +(( random () * 30):: integer ||'
days'):: interval;
insert into optimisation.livraisons (DateLiv ,
DateCom , numC , prestataire)
values(une_date ,t.datecom ,t.numc , 'prest'||(( random
() *20):: integer):: varchar) on conflict do
nothing;
end if;end loop;
end loop;
end;
$$language plpgsql;

```

### Question 3

On exécute la procédure créée précédemment pour insérer des données dans les tables :

```

do $$
begin
call rempli_tables (500);
end
$$;

```

### Question 4

On peut maintenant ajouter les contraintes suivantes :

```

alter table optimisation.commandes add CONSTRAINT fk_commande_client
foreign key (numc)
references optimisation.clients(NumC) on delete cascade not valid;
alter table optimisation.livraisons add constraint fk_livraison_commande
foreign key (
DateCom ,NumC) references optimisation.commandes(DateCom ,NumC) on delete
cascade not
valid;
alter table optimisation.concerne add constraint fk_concerne_commande
foreign key (DateCom
,NumC) references optimisation.commandes(DateCom ,NumC) on delete cascade
not valid;
alter table optimisation.concerne add constraint fk_concerne_produit
foreign key (NumP)
references optimisation.produits(NumP) not valid;

```

### Question 5

On met à jour les statistiques des tables :

```
analyse optimisation.clients , optimisation.commandes ,
optimisation.produits , optimisation.
concerne , optimisation.livraisons;
```

## Question 6

Finalement, on peut afficher ses statistiques avec la commande suivante :

```
analyse verbose optimisation.clients , optimisation.commandes ,
optimisation.produits ,
optimisation.concerne , optimisation.livraisons;

-----
INFO: analyzing "optimisation.clients"
INFO: "clients": scanned 9 of 9 pages, containing 500 live rows and 0 dead
rows; 500 rows in sample, 500 estimated total rows
INFO: finished analyzing table "hotels.optimisation.clients"
avg read rate: 0.000 MB/s, avg write rate: 1.953 MB/s
buffer usage: 58 hits, 0 reads, 1 dirtied
WAL usage: 24 records, 0 full page images, 11635 bytes, 0 buffers full
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s
INFO: analyzing "optimisation.commandes"
INFO: "commandes": scanned 35 of 35 pages, containing 1996 live rows and 0
dead rows; 1996 rows in sample, 1996 estimated total rows
INFO: finished analyzing table "hotels.optimisation.commandes"
avg read rate: 0.000 MB/s, avg write rate: 5.208 MB/s
buffer usage: 91 hits, 0 reads, 2 dirtied
WAL usage: 24 records, 0 full page images, 11645 bytes, 0 buffers full
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s
INFO: analyzing "optimisation.produits"
INFO: "produits": scanned 9 of 9 pages, containing 500 live rows and 0
dead rows; 500 rows in sample, 500 estimated total rows
INFO: finished analyzing table "hotels.optimisation.produits"
avg read rate: 0.000 MB/s, avg write rate: 3.906 MB/s
buffer usage: 58 hits, 0 reads, 1 dirtied
WAL usage: 24 records, 0 full page images, 11643 bytes, 0 buffers full
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s
INFO: analyzing "optimisation.concerne"
INFO: "concerne": scanned 33 of 33 pages, containing 5991 live rows and 0
dead rows; 5991 rows in sample, 5991 estimated total rows
INFO: finished analyzing table "hotels.optimisation.concerne"
avg read rate: 0.000 MB/s, avg write rate: 1.953 MB/s
buffer usage: 85 hits, 0 reads, 1 dirtied
WAL usage: 12 records, 0 full page images, 5892 bytes, 0 buffers full
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s
INFO: analyzing "optimisation.livraisons"
INFO: "livraisons": scanned 10 of 10 pages, containing 1497 live rows and
0 dead rows; 1497 rows in sample, 1497 estimated total rows
INFO: finished analyzing table "hotels.optimisation.livraisons"
```

```
avg read rate: 0.000 MB/s, avg write rate: 0.000 MB/s  
buffer usage: 41 hits, 0 reads, 0 dirtied  
WAL usage: 5 records, 0 full page images, 366 bytes, 0 buffers full  
system usage: CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s  
ANALYZE
```

## Partie 2

Dans cette deuxième partie, nous allons répondre à plusieurs demandes par des requêtes SQL, puis nous allons analyser ces requêtes selon les points suivants :

- Le coût total estimé pour le plan d'exécution et le temps réel de l'exécution
- Le nombre de tuples estimé en sortie et la taille en octets de chaque tuple
- Le nombre de blocs lus
- L'accès utilisés vers les tables
- Les algorithmes utilisés

### Question 1

(REQ1) Listez toutes les informations sur les produits

```
--Requête SQL  
SELECT *  
FROM produits;  
  
--Plan d'exécution  
EXPLAIN (analyse,buffers)  
SELECT *  
FROM produits;  
  
QUERY PLAN  
-----  
Seq Scan on produits  (cost=0.00..14.00 rows=500 width=110) (actual  
time=0.020..0.095 rows=500.00 loops=1)  
  Buffers: shared hit=9  
  Planning Time: 0.078 ms  
  Execution Time: 0.154 ms  
(4 rows)
```

### Analyse:

- **Coût total et temps d'exécution:** Le coût estimé va de 0.00 à 14.00 unités. Le temps d'exécution réel est de 0.154 ms, ce qui est très rapide.
- **Nombre de tuples et taille:** La requête retourne 500 lignes estimées (et effectivement 500 lignes), chaque tuple ayant une largeur de 110 octets (tous les champs de la table produits).
- **Nombre de blocs lus:** 9 blocs ont été lus depuis le cache partagé (shared hit=9), aucune lecture disque n'a été nécessaire.

- **Accès aux tables:** Un parcours séquentiel (Seq Scan) est utilisé sur la table produits, ce qui signifie que toutes les lignes sont parcourues.
- **Algorithmes utilisés:** Parcours séquentiel simple sans filtres ni transformations.

## Question 2

(REQ2) Listez le numéro et le nom de tous les produits

```
--Requête SQL
SELECT nump, nomp
FROM produits;

--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT nump, nomp
FROM produits;

QUERY PLAN
-----
Seq Scan on produits  (cost=0.00..14.00 rows=500 width=13) (actual
time=0.020..0.069 rows=500.00 loops=1)
  Buffers: shared hit=9
  Planning Time: 0.085 ms
  Execution Time: 0.102 ms
(4 rows)
```

## Analyse:

- **Coût total et temps d'exécution:** Le coût estimé est de 0.00 à 14.00 unités. Le temps d'exécution réel est de 0.102 ms, légèrement plus rapide que REQ1 car seules deux colonnes sont retournées.
- **Nombre de tuples et taille:** 500 lignes sont retournées (estimation et réalité concordent), avec une largeur de 13 octets par tuple (seulement nump et nomp).
- **Nombre de blocs lus:** 9 blocs lus depuis le cache partagé (shared hit=9).
- **Accès aux tables:** Parcours séquentiel (Seq Scan) sur la table produits.
- **Algorithmes utilisés:** Parcours séquentiel avec projection de colonnes (sélection de nump et nomp uniquement).

## Question 3

(REQ3) Idem, en ajoutant la clause "distinct"

```
--Requête SQL
SELECT DISTINCT nump, nomp
FROM produits;
```

```
--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT DISTINCT nump, nomp
FROM produits;

QUERY PLAN
-----
HashAggregate  (cost=16.50..21.50 rows=500 width=13) (actual
time=0.328..0.372 rows=500.00 loops=1)
  Group Key: nump, nomp
  Batches: 1  Memory Usage: 57kB
  Buffers: shared hit=9
    -> Seq Scan on produits  (cost=0.00..14.00 rows=500 width=13) (actual
time=0.014..0.121 rows=500.00 loops=1)
        Buffers: shared hit=9
Planning:
  Buffers: shared hit=15
Planning Time: 0.172 ms
Execution Time: 0.432 ms
(10 rows)
```

## Analyse:

- Coût total et temps d'exécution:** Le coût total estimé va de 16.50 à 21.50 unités (plus élevé qu'en REQ2 à cause du HashAggregate). Le temps d'exécution réel est de 0.432 ms.
- Nombre de tuples et taille:** 500 lignes uniques sont retournées avec une largeur de 13 octets par tuple.
- Nombre de blocs lus:** 9 blocs lus depuis le cache (shared hit=9), identique aux requêtes précédentes.
- Accès aux tables:** Parcours séquentiel sur produits, suivi d'un HashAggregate pour éliminer les doublons.
- Algorithmes utilisés:**
  - Parcours séquentiel (Seq Scan)
  - HashAggregate pour implémenter le DISTINCT (utilise 57kB de mémoire avec 1 batch)

## Question 4

(REQ4) Même question en ordonnant le résultat selon le nom des produits

```
--Requête SQL
SELECT DISTINCT nump, nomp
FROM produits
ORDER BY nomp;

--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT DISTINCT nump, nomp
```

```

FROM produits
ORDER BY nomp;

                QUERY PLAN
-----
Unique  (cost=36.41..40.16 rows=500 width=13) (actual time=0.975..1.050
rows=500.00 loops=1)
    Buffers: shared hit=9
        -> Sort  (cost=36.41..37.66 rows=500 width=13) (actual
time=0.974..0.992 rows=500.00 loops=1)
            Sort Key: nomp, nump
            Sort Method: quicksort  Memory: 40kB
            Buffers: shared hit=9
                -> Seq Scan on produits  (cost=0.00..14.00 rows=500 width=13)
(actual time=0.027..0.140 rows=500.00 loops=1)
                    Buffers: shared hit=9
Planning Time: 0.211 ms
Execution Time: 1.103 ms
(10 rows)

```

### Analyse:

- Coût total et temps d'exécution:** Le coût estimé va de 36.41 à 40.16 unités (le plus élevé jusqu'ici à cause du tri). Le temps d'exécution réel est de 1.103 ms.
- Nombre de tuples et taille:** 500 lignes distinctes retournées avec une largeur de 13 octets par tuple.
- Nombre de blocs lus:** 9 blocs lus depuis le cache partagé (shared hit=9).
- Accès aux tables:** Parcours séquentiel sur produits, suivi d'un tri et d'une opération Unique.
- Algorithmes utilisés:**
  - Parcours séquentiel (Seq Scan)
  - Tri (Sort) utilisant l'algorithme quicksort avec 40kB de mémoire
  - Unique pour éliminer les doublons sur les données triées

### Question 5

(REQ5) Listez les produits dont le nom est 'nomp\_ 327'

```

--Requête SQL
SELECT *
FROM produits
WHERE nomp = 'nomp_ 327'; -- Je ne sais pas pourquoi tout mes nomp ont un
espace avant leur numéro

--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT *
FROM produits

```

```

WHERE nomp = 'nomp_ 327';

QUERY PLAN
-----
Seq Scan on produits  (cost=0.00..15.25 rows=1 width=110) (actual
time=0.062..0.091 rows=2.00 loops=1)
  Filter: ((nomp)::text = 'nomp_ 327'::text)
  Rows Removed by Filter: 498
  Buffers: shared hit=9
Planning Time: 0.087 ms
Execution Time: 0.109 ms
(6 rows)

```

### Analyse:

- Coût total et temps d'exécution:** Le coût estimé va de 0.00 à 15.25 unités. Le temps d'exécution réel est de 0.109 ms, très rapide malgré le filtrage.
- Nombre de tuples et taille:** 1 ligne estimée en sortie mais 2 lignes effectivement retournées, avec une largeur de 110 octets (tous les champs).
- Nombre de blocs lus:** 9 blocs lus depuis le cache partagé (shared hit=9).
- Accès aux tables:** Parcours séquentiel (Seq Scan) avec un filtre sur nomp. 498 lignes ont été écartées par le filtre.
- Algorithmes utilisés:** Parcours séquentiel avec filtre (Filter: (nomp)::text = 'nomp\_ 327'::text).

### Question 6

(REQ6) Donnez le nombre de commandes par client (numc, nombre)

```

--Requête SQL
SELECT numc, COUNT(*) AS nombre
FROM commandes
GROUP BY numc;

--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT numc, COUNT(*) AS nombre
FROM commandes
GROUP BY numc;

QUERY PLAN
-----
HashAggregate  (cost=64.94..69.86 rows=492 width=12) (actual
time=0.451..0.497 rows=492.00 loops=1)
  Group Key: numc
  Batches: 1  Memory Usage: 73kB
  Buffers: shared hit=35
    -> Seq Scan on commandes  (cost=0.00..54.96 rows=1996 width=4) (actual

```

```

time=0.021..0.147 rows=1996.00 loops=1)
    Buffers: shared hit=35
Planning Time: 0.132 ms
Execution Time: 0.555 ms
(8 rows)

```

## Analyse:

- Coût total et temps d'exécution:** Le coût estimé va de 64.94 à 69.86 unités. Le temps d'exécution réel est de 0.555 ms.
- Nombre de tuples et taille:** 492 lignes estimées (et effectivement retournées) avec une largeur de 12 octets par tuple (numc en integer + count en bigint).
- Nombre de blocs lus:** 35 blocs lus depuis le cache partagé (shared hit=35), plus que pour la table produits car la table commandes est plus grande.
- Accès aux tables:** Parcours séquentiel sur la table commandes (1996 lignes lues), suivi d'un HashAggregate pour le regroupement.
- Algorithmes utilisés:**
  - Parcours séquentiel (Seq Scan) sur commandes
  - HashAggregate pour implémenter le GROUP BY (utilise 73kB de mémoire avec 1 batch)

## Question 7

(REQ7) Donnez les infos sur chaque commande, sous la forme ('nom du client', 'date de la commande'). Quelle est la méthode de jointure utilisée ? Pourquoi les relations sont elles considérées dans cet ordre dans le plan d'exécution ? Pourquoi la table commande n'est pas utilisée en fait ?

```

--Requête SQL
SELECT cl.nomc AS "Nom du client", co.datecom as "Date de la commande"
FROM commandes AS co
JOIN clients AS cl ON co.numc = cl.numc;

--Plan d'exécution
EXPLAIN (analyse,buffers)
SELECT cl.nomc AS "Nom du client", co.datecom as "Date de la commande"
FROM commandes AS co
JOIN clients AS cl ON co.numc = cl.numc;

          QUERY PLAN
-----
Hash Join  (cost=20.25..80.49 rows=1996 width=13) (actual
time=0.269..1.762 rows=1996.00 loops=1)
  Hash Cond: (co.numc = cl.numc)
  Buffers: shared hit=44
    -> Seq Scan on commandes co  (cost=0.00..54.96 rows=1996 width=8)
(actual time=0.012..0.353 rows=1996.00 loops=1)
    Buffers: shared hit=35

```

```

-> Hash  (cost=14.00..14.00 rows=500 width=13) (actual
time=0.229..0.231 rows=500.00 loops=1)
    Buckets: 1024  Batches: 1  Memory Usage: 32kB
    Buffers: shared hit=9
-> Seq Scan on clients cl  (cost=0.00..14.00 rows=500 width=13)
(actual time=0.012..0.108 rows=500.00 loops=1)
    Buffers: shared hit=9
Planning:
    Buffers: shared hit=6
Planning Time: 0.345 ms
Execution Time: 2.062 ms
(14 rows)

```

## Analyse:

- Coût total et temps d'exécution:** Le coût total estimé va de 20.25 à 80.49 unités. Le temps d'exécution réel est de 2.062 ms.
- Nombre de tuples et taille:** 1996 lignes retournées (estimation et réalité concordent) avec une largeur de 13 octets par tuple (nomc + datecom).
- Nombre de blocs lus:** 44 blocs au total lus depuis le cache (35 pour commandes + 9 pour clients).
- Accès aux tables:**
  - Parcours séquentiel sur la table commandes (1996 lignes)
  - Parcours séquentiel sur la table clients (500 lignes) pour construire la table de hachage
  - Hash Join pour combiner les deux tables
- Algorithmes utilisés:**
  - Seq Scan sur les deux tables
  - Hash Join: la table clients (plus petite) est utilisée pour construire une table de hachage (32kB, 1024 buckets, 1 batch), puis la table commandes est parcourue pour trouver les correspondances
  - La méthode Hash Join est choisie car elle est efficace pour joindre deux tables de tailles moyennes
  - L'ordre (commandes puis clients) est choisi car clients est plus petite et peut être chargée entièrement en mémoire dans la table de hachage

## Question 8

Pour cette question, on nous donne la requête SQL suivante :

```

explain -- Attention , pas de mot clé "analyse" ici car la requête ne
termine pas !
select distinct nomc , nomp
from optimisation.clients ,optimisation.concerne , optimisation.produits ,
optimisation.commandes ,
optimisation.livraisons

```

```

where optimisation.clients.numc = optimisation.commandes.numc
and optimisation.commandes.datecom = optimisation.concerne.datecom
and optimisation.commandes.numc=optimisation.concerne.numc
and optimisation.produits.nump=optimisation.concerne.nump;

```

#### QUERY PLAN

```

HashAggregate  (cost=98217.11..99026.51 rows=80940 width=18)
  Group Key: clients.nomc, produits.nomp
    -> Merge Join  (cost=541.30..53374.48 rows=8968527 width=18)
      Merge Cond: ((commandes.datecom = concerne.datecom) AND
(commandes.numc = clients.numc))
        -> Nested Loop  (cost=0.28..37453.08 rows=2988012 width=8)
          -> Index Only Scan using commandes_pkey on commandes
(cost=0.28..74.22 rows=1996 width=8)
          -> Materialize  (cost=0.00..32.45 rows=1497 width=0)
            -> Seq Scan on livraisons  (cost=0.00..24.97
rows=1497 width=0)
        -> Sort  (cost=541.02..556.00 rows=5991 width=30)
          Sort Key: concerne.datecom, clients.numc
          -> Hash Join  (cost=40.50..165.13 rows=5991 width=30)
            Hash Cond: (concerne.nump = produits.nump)
            -> Hash Join  (cost=20.25..129.02 rows=5991 width=25)
              Hash Cond: (concerne.numc = clients.numc)
              -> Seq Scan on concerne  (cost=0.00..92.91
rows=5991 width=12)
              -> Hash  (cost=14.00..14.00 rows=500 width=13)
                -> Seq Scan on clients  (cost=0.00..14.00
rows=500 width=13)
            -> Hash  (cost=14.00..14.00 rows=500 width=13)
              -> Seq Scan on produits  (cost=0.00..14.00
rows=500 width=13)
(19 rows)

```

#### Analyse:

- Coût total et temps d'exécution:** Le coût total estimé est extrêmement élevé, allant de 98217.11 à 99026.51 unités. Le temps d'exécution réel n'est pas disponible car la requête n'a pas été exécutée avec ANALYZE (elle ne termine pas dans un temps raisonnable).
- Nombre de tuples et taille:** 80940 lignes distinctes estimées en sortie avec une largeur de 18 octets par tuple (nomc + nomp). L'estimation intermédiaire du Merge Join est de 8968527 lignes, ce qui est énorme.
- Nombre de blocs lus:** Non disponible sans exécution réelle.
- Accès aux tables:**
  - Index Only Scan sur commandes (via commandes\_pkey)
  - Seq Scan sur livraisons (1497 lignes)
  - Seq Scan sur concerne (5991 lignes)
  - Seq Scan sur clients (500 lignes)

- Seq Scan sur produits (500 lignes)

- **Algorithmes utilisés:**

- **Nested Loop:** Jointure en boucle imbriquée entre commandes et livraisons, produisant 2988012 lignes estimées (produit cartésien car aucune condition de jointure entre ces tables)
- **Hash Join:** Utilisé deux fois pour joindre commandes avec clients puis avec produits
- **Sort:** Tri des résultats de la jointure hash avant le Merge Join
- **Merge Join:** Jointure par fusion entre le résultat du Nested Loop et les données triées
- **HashAggregate:** Pour implémenter le DISTINCT final
- **Materialize:** Pour matérialiser la table livraisons dans la boucle imbriquée

**Problème:** La table livraisons n'a aucune condition de jointure avec les autres tables, ce qui crée un produit cartésien massif. Chaque ligne de commandes est combinée avec toutes les lignes de livraisons, multipliant artificiellement le nombre de lignes intermédiaires.

## Partie 3

Dans cette troisième partie, une série de requêtes SQL nous est proposée afin d'analyser leurs plans d'exécution, puis d'optimiser ces requêtes en créant des index appropriés.

### Question 1

On nous donne la commande SQL pour afficher la liste des index existants dans le schéma optimisation :

```

SELECT
    tablename ,
    indexname ,
    indexdef
FROM
    pg_indexes
WHERE
    schemaname = 'optimisation '
ORDER BY
    tablename ,
    indexname;

```

tablename   indexname   indexdef
(0 rows)

Pour le début de cette partie, aucun index n'a été créé sur aucune table du schéma optimisation.

### Question 2

Pour les trois requêtes de cette question, on commence par afficher le plan d'exécution, puis on l'affiche sous forme de graphique en arbre.

1. Requête 1

```
--Requête SQL
Select *
from optimisation.commandes
where numC='116'
and datecom='2025-09-01';

--Plan d'exécution
EXPLAIN (analyse,buffers)
Select *
from optimisation.commandes
where numC='116'
and datecom='2025-09-01';

-----  

          QUERY PLAN  

-----  

Index Scan using commandes_pkey on commandes (cost=0.28..8.30 rows=1
width=105) (actual time=0.034..0.037 rows=1.00 loops=1)
  Index Cond: ((datecom = '2025-09-01'::date) AND (numc = 116))
  Index Searches: 1
  Buffers: shared hit=3
Planning Time: 0.165 ms
Execution Time: 0.071 ms
(6 rows)
```

**Index Scan**

on commandes  
using commandes\_pkey

**Index Scan Node** finds relevant records based on an **Index**. Index Scans perform 2 read operations: one to read the index and another to read the actual value from the table.

General	IO & Buffers	Output	Workers	Misc
⌚ <b>Timing:</b> 0.037ms   52%				
☰ <b>Rows:</b> 1 (Planned: 1)				
฿ <b>Cost:</b> 8.30 (Total: 8.30)				

## 2. Requête 2

```
--Requête SQL
Select *
from optimisation.commandes
where datecom='2025-09-01';
```

```
--Plan d'exécution
EXPLAIN (analyse,buffers)
Select *
from optimisation.commandes
where datecom='2025-09-01';
```

#### QUERY PLAN

```
-----  
Index Scan using commandes_pkey on commandes (cost=0.28..8.29 rows=1  
width=105) (actual time=0.031..0.034 rows=1.00 loops=1)  
  Index Cond: (datecom = '2025-09-01'::date)  
  Index Searches: 1  
  Buffers: shared hit=3  
Planning Time: 0.144 ms  
Execution Time: 0.067 ms  
(6 rows)
```

### Index Scan

on commandes  
using commandes\_pkey



**Index Scan Node** finds relevant records based on an **Index**. Index Scans perform 2 read operations: one to read the index and another to read the actual value from the table.

General    IO & Buffers    Output    Workers    Misc

⌚ Timing: 0.034ms | 51%

☰ Rows: 1 (Planned: 1)

\$ Cost: 8.29 (Total: 8.29)

### 3. Requête 3

```
--Requête SQL
Select *
from optimisation.commandes
where numC='116';

--Plan d'exécution
EXPLAIN (analyse,buffers)
Select *
from optimisation.commandes
where numC='116';
```

## QUERY PLAN

```
--  
Seq Scan on commandes  (cost=0.00..59.95 rows=6 width=105) (actual  
time=0.036..0.529 rows=6.00 loops=1)  
  Filter: (numc = 116)  
  Rows Removed by Filter: 1990  
  Buffers: shared hit=35  
Planning Time: 0.146 ms  
Execution Time: 0.561 ms  
(6 rows)
```

**Seq Scan** on commandes

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General    IO & Buffers    Output    Workers    Misc

⌚ **Timing:** 0.529ms | 94%

☰ **Rows:** 6 (Planned: 6)

▼ **\*Rows Removed by Filter:** 1,990 | 99% ⓘ

\$ **Cost:** 59.95 (Total: 59.95)

On remarque que pour les deux premières requêtes, le plan d'exécution utilise un "Index Scan" sur l'index primaire 'commandes\_pkey', ce qui permet un accès rapide aux enregistrements correspondants. Cependant, pour la troisième requête, le plan d'exécution utilise un parcours séquentiel car il n'y a pas d'index sur la colonne 'numC' seule, ce qui entraîne une lecture complète de la table commandes qui est moins efficace. De ce fait, si la recherche par 'numC' est fréquente, il serait judicieux de créer un index sur cette colonne pour améliorer les performances des requêtes similaires à la troisième.

### Question 3

On nous donne la commande SQL suivante :

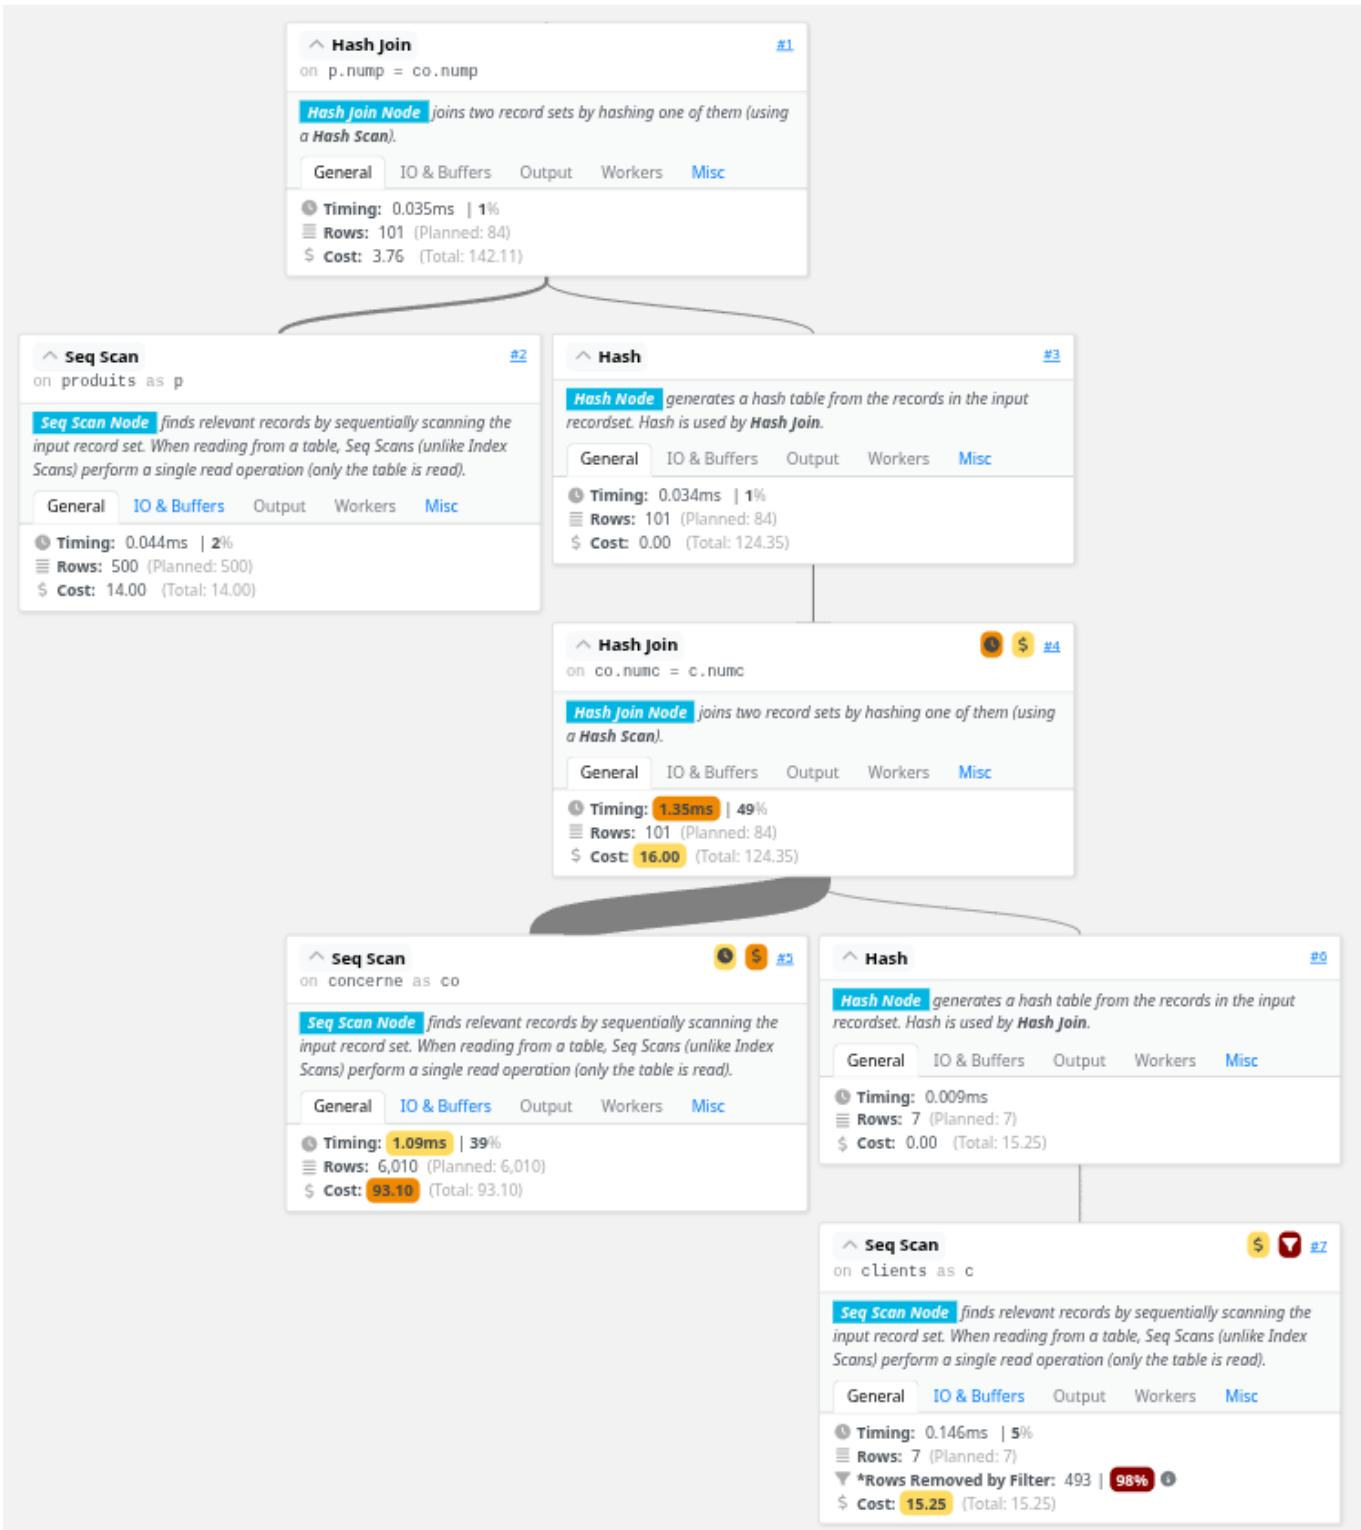
```
Select nomp  
from optimisation.produits p  
join optimisation.concerne co using(nump)
```

```
join optimisation.clients c using(numc)
where nomc='nomc_ 7';
```

On donne donc son plan d'exécution :

```
EXPLAIN (analyse,buffers)
Select nomp
from optimisation.produits p
join optimisation.concerne co using(nump)
join optimisation.clients c using(numc)
where nomc='nomc_ 7';

QUERY PLAN
-----
Hash Join  (cost=125.40..142.11 rows=84 width=9) (actual time=2.652..2.705
rows=101.00 loops=1)
  Hash Cond: (p.nump = co.nump)
  Buffers: shared hit=51
    -> Seq Scan on produits p  (cost=0.00..14.00 rows=500 width=13) (actual
       time=0.019..0.044 rows=500.00 loops=1)
        Buffers: shared hit=9
    -> Hash  (cost=124.35..124.35 rows=84 width=4) (actual
       time=2.626..2.626 rows=101.00 loops=1)
      Buckets: 1024  Batches: 1  Memory Usage: 12kB
      Buffers: shared hit=42
        -> Hash Join  (cost=15.34..124.35 rows=84 width=4) (actual
           time=0.237..2.592 rows=101.00 loops=1)
          Hash Cond: (co.numc = c.numc)
          Buffers: shared hit=42
            -> Seq Scan on concerne co  (cost=0.00..93.10 rows=6010
               width=8) (actual time=0.013..1.088 rows=6010.00 loops=1)
              Buffers: shared hit=33
            -> Hash  (cost=15.25..15.25 rows=7 width=4) (actual
               time=0.155..0.155 rows=7.00 loops=1)
              Buckets: 1024  Batches: 1  Memory Usage: 9kB
              Buffers: shared hit=9
                -> Seq Scan on clients c  (cost=0.00..15.25 rows=7
                   width=4) (actual time=0.021..0.146 rows=7.00 loops=1)
                  Filter: ((nomc)::text = 'nomc_ 7'::text)
                  Rows Removed by Filter: 493
                  Buffers: shared hit=9
Planning:
  Buffers: shared hit=49
Planning Time: 1.134 ms
Execution Time: 2.775 ms
(24 rows)
```



Pour optimiser cette requête, on peut créer les deux index suivants :

```
CREATE INDEX idx_clients_nomc ON optimisation.clients(nomc);
CREATE INDEX idx_concerne_numc ON optimisation.concerne(numc);
```

```
analyse optimisation.clients , optimisation.commandes ,
optimisation.produits , optimisation.
concerne , optimisation.livraisons;
```

Le plan d'exécution après création des index devient :

```

EXPLAIN (analyse,buffers)
Select nomp
from optimisation.produits p
join optimisation.concerne co using(nump)
join optimisation.clients c using(numc)
where nomc='nomc_ 7';

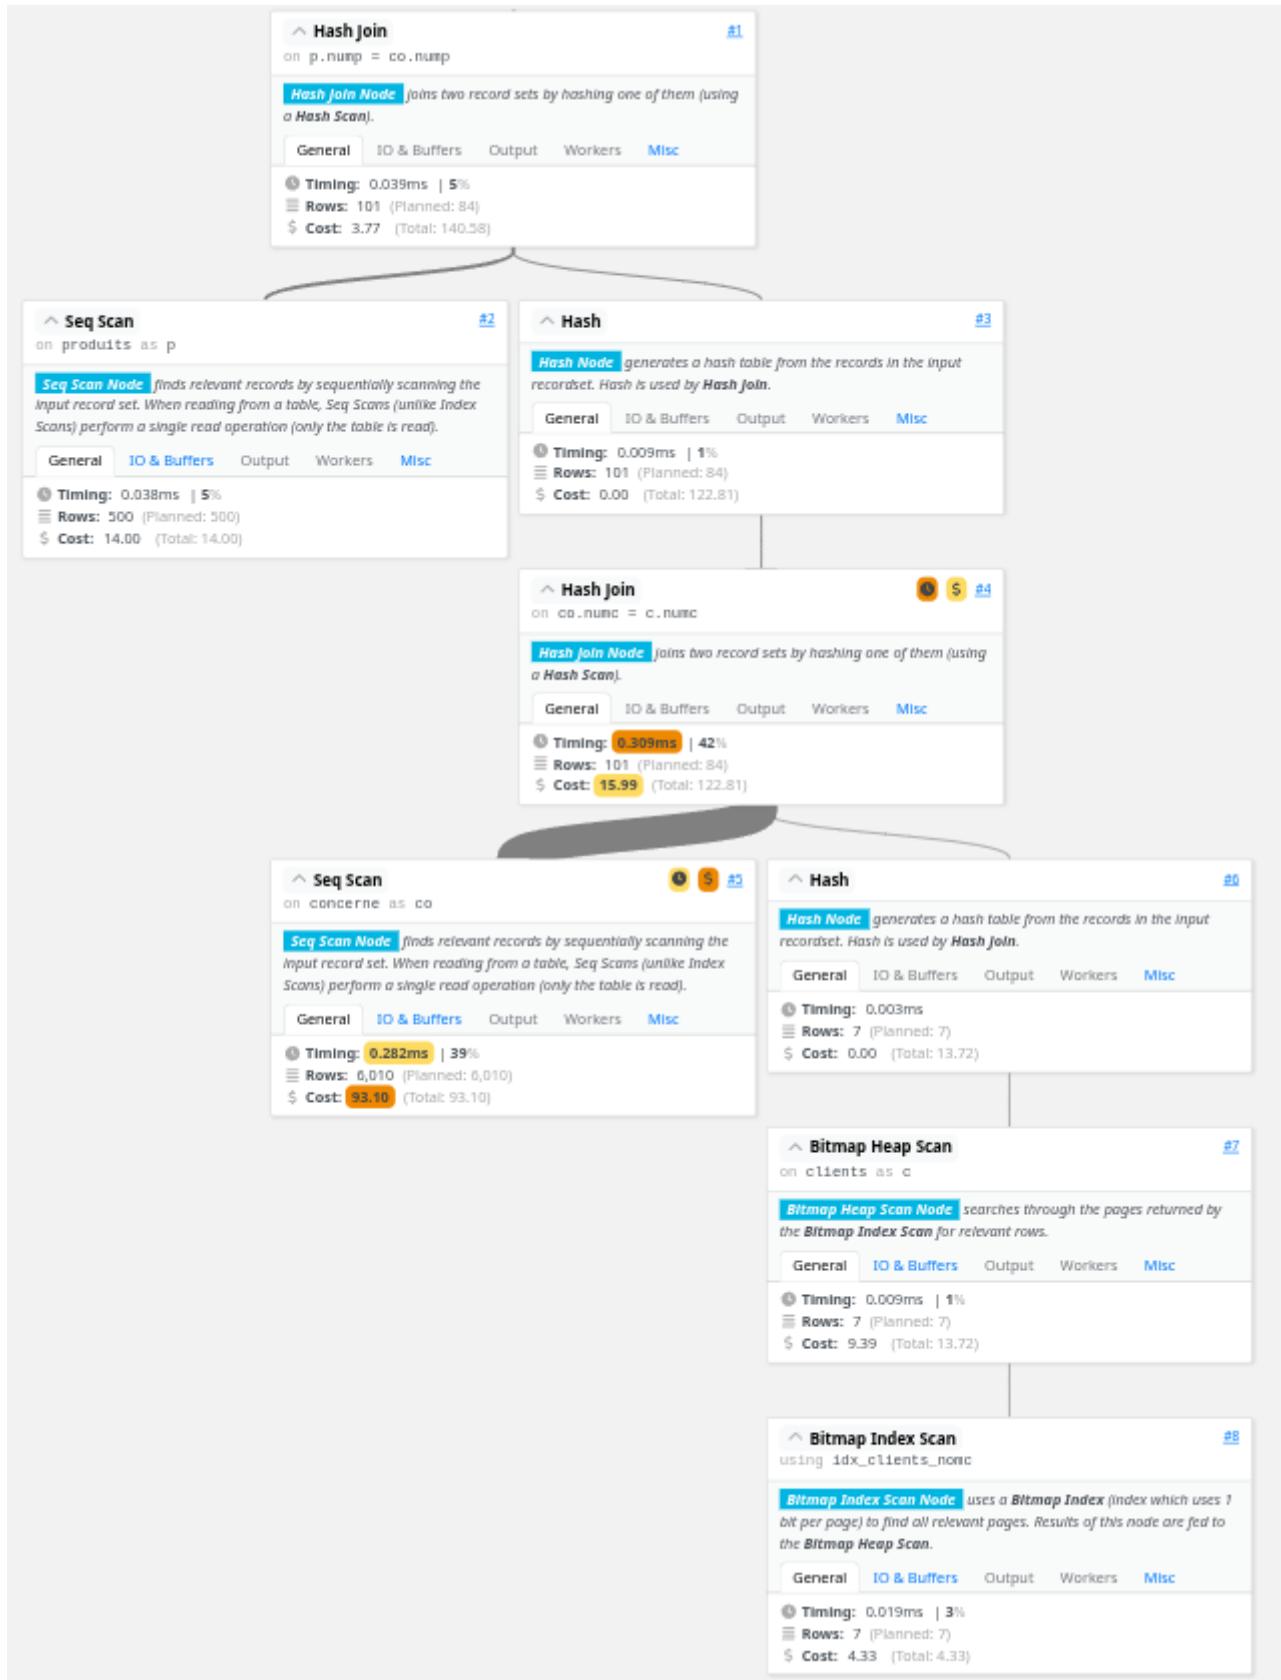
```

#### QUERY PLAN

```

-----
Hash Join  (cost=123.86..140.58 rows=84 width=9) (actual time=0.637..0.708
rows=101.00 loops=1)
  Hash Cond: (p.nump = co.nump)
  Buffers: shared hit=49 read=2
    -> Seq Scan on produits p  (cost=0.00..14.00 rows=500 width=13) (actual
       time=0.005..0.038 rows=500.00 loops=1)
        Buffers: shared hit=9
    -> Hash  (cost=122.81..122.81 rows=84 width=4) (actual
       time=0.629..0.631 rows=101.00 loops=1)
      Buckets: 1024  Batches: 1  Memory Usage: 12kB
      Buffers: shared hit=40 read=2
        -> Hash Join  (cost=13.80..122.81 rows=84 width=4) (actual
           time=0.047..0.622 rows=101.00 loops=1)
          Hash Cond: (co.numc = c.numc)
          Buffers: shared hit=40 read=2
            -> Seq Scan on concerne co  (cost=0.00..93.10 rows=6010
               width=8) (actual time=0.003..0.282 rows=6010.00 loops=1)
              Buffers: shared hit=33
            -> Hash  (cost=13.72..13.72 rows=7 width=4) (actual
               time=0.031..0.031 rows=7.00 loops=1)
              Buckets: 1024  Batches: 1  Memory Usage: 9kB
              Buffers: shared hit=7 read=2
                -> Bitmap Heap Scan on clients c  (cost=4.33..13.72
                   rows=7 width=4) (actual time=0.024..0.028 rows=7.00 loops=1)
                  Recheck Cond: ((nomc)::text = 'nomc_ 7'::text)
                  Heap Blocks: exact=7
                  Buffers: shared hit=7 read=2
                    -> Bitmap Index Scan on idx_clients_nomc
                      (cost=0.00..4.33 rows=7 width=0) (actual time=0.019..0.019 rows=7.00
                       loops=1)
                      Index Cond: ((nomc)::text = 'nomc_
                      7'::text)
                      Index Searches: 1
                      Buffers: shared read=2
Planning:
  Buffers: shared hit=52 read=5
Planning Time: 1.190 ms
Execution Time: 0.730 ms
(28 rows)

```



On peut maintenant supprimer les index créés précédemment pour ne pas impacter les prochaines questions

```
DROP INDEX IF EXISTS idx_clients_nomc;
DROP INDEX IF EXISTS idx_concerne_numc;
```

On remarque que le temps d'exécution est passé de 2.775 ms à 0.730 ms, soit une amélioration significative des performances grâce aux index créés.

#### Question 4

Pour cette question, on veut comparer les plans d'exécutions des trois requêtes suivantes :

##### 1. Requête 1

```
--Requête SQL
Select numc
from optimisation.clients
where numc not in
(select numc from optimisation.livraisons);

--Plan d'exécution
EXPLAIN (analyse,buffers)
Select numc
from optimisation.clients
where numc not in
(select numc from optimisation.livraisons);

-----  
QUERY PLAN  
-----
Seq Scan on clients  (cost=28.79..44.04 rows=250 width=4) (actual
time=0.476..0.576 rows=90.00 loops=1)
  Filter: (NOT (ANY (numc = (hashed SubPlan 1).col1)))
  Rows Removed by Filter: 410
  Buffers: shared hit=19
  SubPlan 1
    -> Seq Scan on livraisons  (cost=0.00..25.03 rows=1503 width=4)
(actual time=0.004..0.188 rows=1503.00 loops=1)
    Buffers: shared hit=10
Planning:
  Buffers: shared hit=25 dirtied=5
Planning Time: 0.245 ms
Execution Time: 0.602 ms
(11 rows)
```

##### 2. Requête 2

```
--Requête SQL
Select numc
from optimisation.clients
except
select numc
from optimisation.livraisons;

--Plan d'exécution
EXPLAIN (analyse,buffers)
```

```

Select numc
from optimisation.clients
except
select numc
from optimisation.livraisons;

                QUERY PLAN
-----
 HashSetOp Except  (cost=44.04..45.29 rows=500 width=4) (actual
time=1.377..1.428 rows=90.00 loops=1)
    Buffers: shared hit=19
        -> Seq Scan on clients  (cost=0.00..14.00 rows=500 width=4) (actual
time=0.025..0.180 rows=500.00 loops=1)
            Buffers: shared hit=9
        -> Seq Scan on livraisons  (cost=0.00..25.03 rows=1503 width=4) (actual
time=0.008..0.410 rows=1503.00 loops=1)
            Buffers: shared hit=10
 Planning Time: 0.195 ms
 Execution Time: 1.484 ms
(8 rows)

```

### 3. Requête 3

```

--Requête SQL
Select numc
from optimisation.clients
where not exists
(select numc from optimisation.livraisons
where optimisation.livraisons.numc=optimisation.clients.numc);

--Plan d'exécution
EXPLAIN (analyse,buffers)
Select numc
from optimisation.clients
where not exists
(select numc from optimisation.livraisons
where optimisation.livraisons.numc=optimisation.clients.numc);

                QUERY PLAN
-----
 Hash Right Anti Join  (cost=20.25..62.93 rows=90 width=4) (actual
time=1.309..1.363 rows=90.00 loops=1)
    Hash Cond: (livraisons.numc = clients.numc)
    Buffers: shared hit=19
        -> Seq Scan on livraisons  (cost=0.00..25.03 rows=1503 width=4) (actual
time=0.009..0.296 rows=1503.00 loops=1)
            Buffers: shared hit=10
        -> Hash  (cost=14.00..14.00 rows=500 width=4) (actual time=0.368..0.370
rows=500.00 loops=1)
            Buckets: 1024  Batches: 1  Memory Usage: 26kB
            Buffers: shared hit=9

```

```

-> Seq Scan on clients  (cost=0.00..14.00 rows=500 width=4)
(actual time=0.020..0.182 rows=500.00 loops=1)
      Buffers: shared hit=9
Planning:
      Buffers: shared hit=12
Planning Time: 0.539 ms
Execution Time: 1.420 ms
(14 rows)

```

## Comparaison des plans d'exécution :

Les trois requêtes produisent le même résultat (90 clients qui n'ont pas de livraisons) mais utilisent des stratégies d'exécution différentes avec des performances distinctes :

### 1. Approche NOT IN (Requête 1) - La plus performante

- **Temps d'exécution** : 0.602 ms
- **Coût estimé** : 44.04 unités
- **Stratégie** : Utilise un "Hashed SubPlan" où la sous-requête est exécutée une seule fois pour créer une table de hachage en mémoire des numc de livraisons. Ensuite, un parcours séquentiel de clients vérifie pour chaque ligne si le numc est présent dans cette table de hachage.
- **Avantages** : C'est la méthode la plus rapide car la recherche dans une table de hachage est en O(1). La sous-requête n'est exécutée qu'une seule fois (1503 lignes lues).
- **Inconvénient potentiel** : Peut être problématique si la sous-requête retourne des valeurs NULL (comportement spécifique de NOT IN).

### 2. Approche EXCEPT (Requête 2) - Performance moyenne

- **Temps d'exécution** : 1.484 ms (2.5x plus lent que NOT IN)
- **Coût estimé** : 45.29 unités
- **Stratégie** : Utilise "HashSetOp Except" qui traite les deux ensembles comme des opérations ensemblistes. Les deux tables sont parcourues séquentiellement (500 clients + 1503 livraisons = 2003 lignes) et un HashSetOp effectue la différence ensembliste.
- **Avantages** : Sémantique claire et standard SQL. Gère automatiquement les NULL et élimine les doublons.
- **Inconvénient** : Plus lent car nécessite de traiter toutes les lignes des deux tables avant de calculer la différence. Plus coûteux en mémoire pour gérer les deux ensembles.

### 3. Approche NOT EXISTS (Requête 3) - Performance moyenne-bonne

- **Temps d'exécution** : 1.420 ms (2.4x plus lent que NOT IN)
- **Coût estimé** : 62.93 unités (le plus élevé)
- **Stratégie** : Utilise un "Hash Right Anti Join" où clients est chargé dans une table de hachage (26kB, 1024 buckets), puis livraisons est parcourue pour trouver les correspondances et les éliminer (anti-jointure).
- **Avantages** : Excellente pour les requêtes corrélées car l'optimiseur peut la transformer en anti-jointure efficace. Sémantique claire et gestion correcte des NULL.
- **Inconvénient** : Le coût estimé est le plus élevé (62.93) bien que le temps d'exécution soit similaire à EXCEPT. Nécessite plus de mémoire pour la table de hachage.

## Conclusions :

- NOT IN est clairement le plus performant (0.602 ms vs ~1.4 ms pour les autres).
- NOT IN bénéficie d'une optimisation spéciale avec le "Hashed SubPlan" qui évite une jointure coûteuse.
- EXCEPT et NOT EXISTS ont des performances similaires mais utilisent des stratégies différentes

## Question 5

On nous donne la commande suivante qu'il va falloir optimiser :

```
Select upper(nomc), adressec  
From clients  
Where upper(nomc)='NOMC_ 7';
```

On donne son plan d'exécution initial :

```
EXPLAIN (analyse,buffers)  
Select upper(nomc), adressec  
From clients  
Where upper(nomc)='NOMC_ 7';  
  
QUERY PLAN  
-----  
Seq Scan on clients  (cost=0.00..16.50 rows=2 width=129) (actual  
time=0.244..0.780 rows=7.00 loops=1)  
  Filter: (upper((nomc)::text) = 'NOMC_ 7'::text)  
  Rows Removed by Filter: 493  
  Buffers: shared hit=9  
Planning:  
  Buffers: shared hit=14  
Planning Time: 0.243 ms  
Execution Time: 0.810 ms  
(8 rows)
```

**Seq Scan**

on clients

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General	IO & Buffers	Output	Workers	Misc
<b>Timing:</b> 0.78ms   96%				
<b>Rows:</b> 7 (Planned: 2)				
<b>*Rows Removed by Filter:</b> 493   98% <small>i</small>				
<b>Cost:</b> 16.50 (Total: 16.50)				

Pour optimiser cette requête, on peut créer un index fonctionnel sur la colonne `nomc` en utilisant la fonction `upper`. Cela permettra à PostgreSQL d'utiliser l'index lors de l'exécution de la requête, évitant ainsi un parcours séquentiel complet de la table.

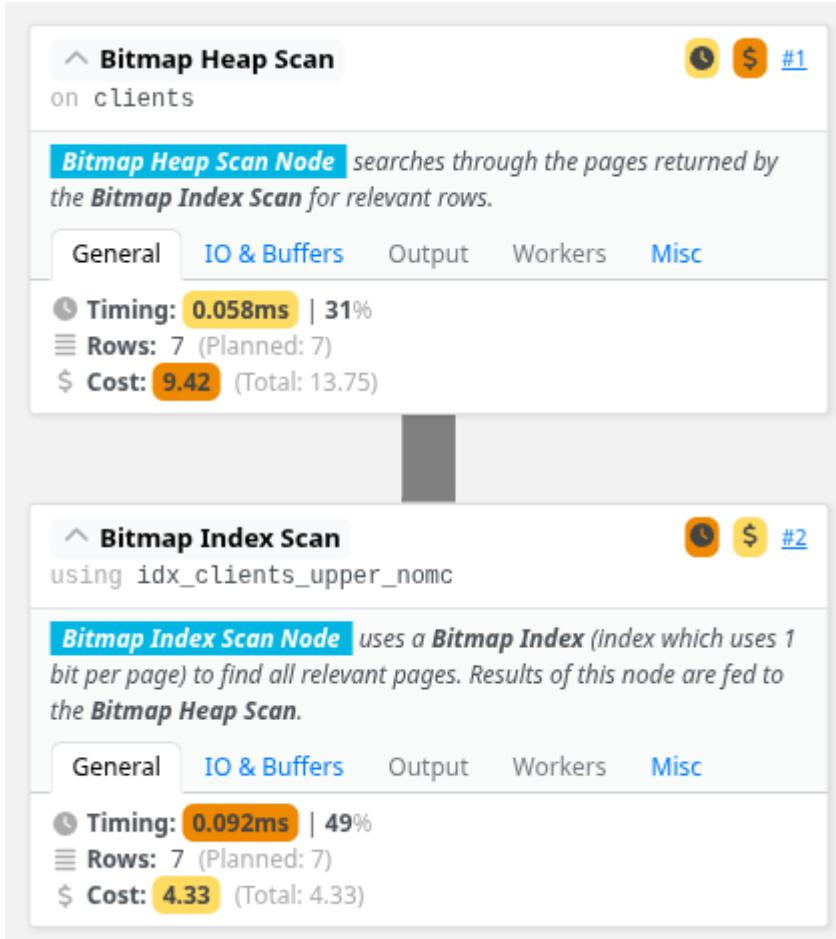
```
CREATE INDEX idx_clients_upper_nomc ON optimisation.clients(upper(nomc));
analyse optimisation.clients;
```

Le plan d'exécution après création de l'index devient :

```
EXPLAIN (analyse,buffers)
Select upper(nomc), adressec
From clients
Where upper(nomc)='NOMC_ 7';

QUERY PLAN
-----
Bitmap Heap Scan on clients  (cost=4.33..13.75 rows=7 width=129) (actual
time=0.127..0.150 rows=7.00 loops=1)
  Recheck Cond: (upper((nomc)::text) = 'NOMC_ 7'::text)
  Heap Blocks: exact=7
  Buffers: shared hit=7 read=2
    -> Bitmap Index Scan on idx_clients_upper_nomc  (cost=0.00..4.33 rows=7
width=0) (actual time=0.091..0.092 rows=7.00 loops=1)
      Index Cond: (upper((nomc)::text) = 'NOMC_ 7'::text)
      Index Searches: 1
      Buffers: shared read=2
Planning:
  Buffers: shared hit=15 read=1
Planning Time: 0.459 ms
```

Execution Time: 0.188 ms  
(12 rows)



On peut maintenant supprimer l'index créé précédemment pour ne pas impacter les prochaines questions :

```
DROP INDEX IF EXISTS idx_clients_upper_nomc;
```

## Question 6

Pour cette question, on nous donne une requête SQL mal écrite qu'il va falloir optimiser :

```
SELECT COUNT (*)
FROM commandes
WHERE EXTRACT(YEAR FROM datecom) = 2017;
```

On donne son plan d'exécution initial :

```
EXPLAIN (analyse,buffers)
SELECT COUNT (*)
FROM commandes
WHERE EXTRACT(YEAR FROM datecom) = 2017;
```

## QUERY PLAN

```
Aggregate (cost=64.94..64.95 rows=1 width=8) (actual time=0.356..0.356
rows=1.00 loops=1)
  Buffers: shared hit=35
    -> Seq Scan on commandes (cost=0.00..64.91 rows=10 width=0) (actual
time=0.026..0.341 rows=208.00 loops=1)
      Filter: (EXTRACT(year FROM datecom) = '2017'::numeric)
      Rows Removed by Filter: 1786
      Buffers: shared hit=35
Planning:
  Buffers: shared hit=16 read=1 dirtied=1
Planning Time: 0.359 ms
Execution Time: 0.389 ms
(10 rows)
```

### Aggregate #1

**Aggregate Node** groups records together based on a GROUP BY or aggregate function (like `sum()`).

General IO & Buffers Output Workers Misc

⌚ **Timing:** 0.015ms | 4%

≡ **Rows:** 1 (Planned: 1)

\$ **Cost:** 0.04 (Total: 64.95)

### Seq Scan #2

on commandes



#2

**Seq Scan Node** finds relevant records by sequentially scanning the input record set. When reading from a table, Seq Scans (unlike Index Scans) perform a single read operation (only the table is read).

General IO & Buffers Output Workers Misc

⌚ **Timing:** 0.341ms | 88%

≡ **Rows:** 208 (Planned: 10) | ↓ under estimated by 21 ×

▼ \***Rows Removed by Filter:** 1,786 | 89% ⓘ

\$ **Cost:** 64.91 (Total: 64.91)

Ici, la clé primaire n'est pas utilisée car la fonction EXTRACT empêche l'utilisation d'un index sur datecom. Pour optimiser cette requête, on peut reformuler la condition pour utiliser une plage de dates, ce qui permettra à PostgreSQL d'utiliser un index sur datecom si disponible.

Voici la requête optimisée :

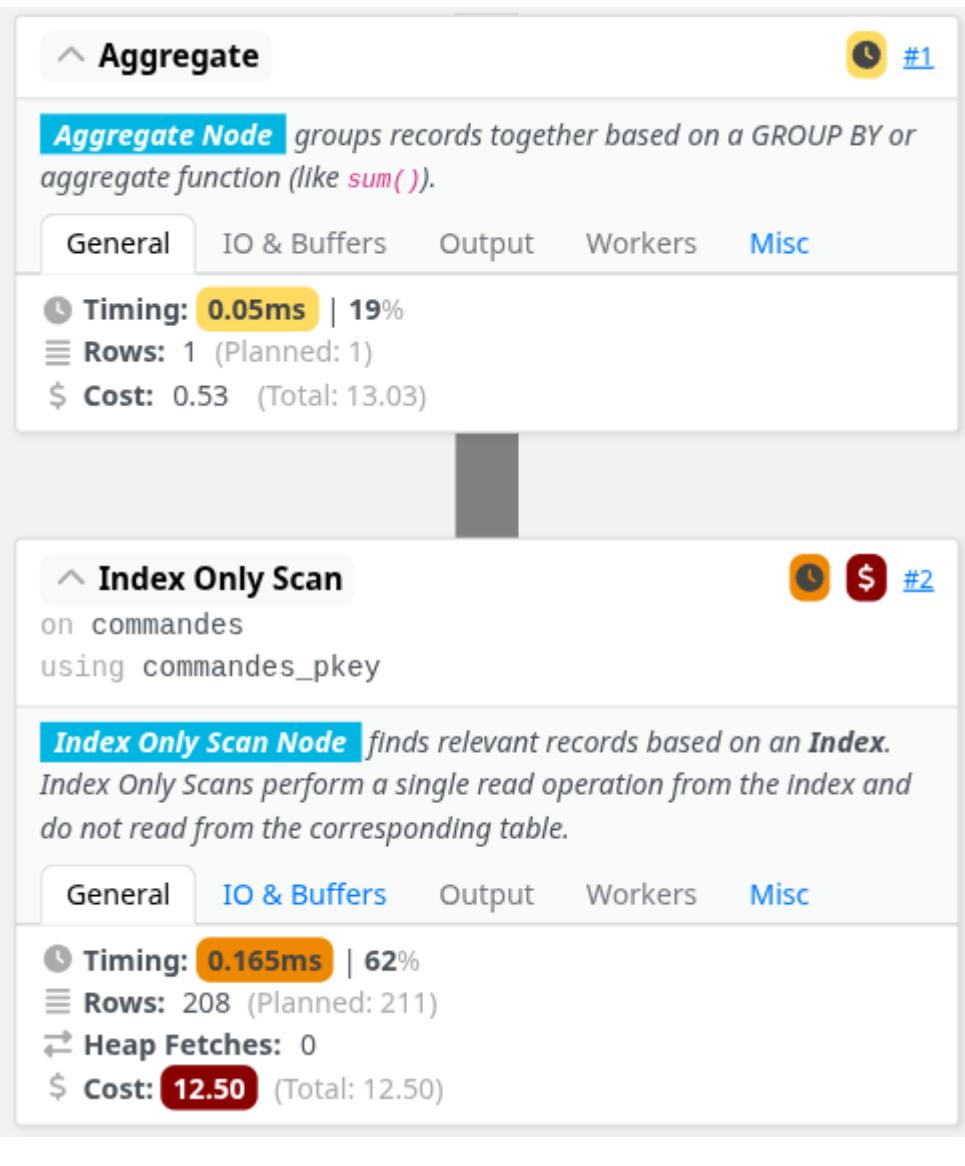
```

--Requête SQL optimisée
SELECT COUNT (*)
FROM commandes
WHERE datecom >= '2017-01-01' AND datecom < '2018-01-01';

--Plan d'exécution optimisé
EXPLAIN (analyse,buffers)
SELECT COUNT (*)
FROM commandes
WHERE datecom >= '2017-01-01' AND datecom < '2018-01-01';

          QUERY PLAN
-----
Aggregate (cost=13.02..13.03 rows=1 width=8) (actual time=0.213..0.215
rows=1.00 loops=1)
  Buffers: shared hit=4
    -> Index Only Scan using commandes_pkey on commandes (cost=0.28..12.50
rows=211 width=0) (actual time=0.079..0.165 rows=208.00 loops=1)
          Index Cond: ((datecom >= '2017-01-01'::date) AND (datecom < '2018-
01-01'::date))
          Heap Fetches: 0
          Index Searches: 1
          Buffers: shared hit=4
Planning:
  Buffers: shared hit=3
Planning Time: 0.228 ms
Execution Time: 0.265 ms
(11 rows)

```



On remarque que l'index sur la clé primaire `commandes_pkey` est maintenant utilisé, ce qui améliore considérablement les performances de la requête. Le temps d'exécution est passé de 0.389 ms à 0.265 ms, et le nombre de blocs lus a diminué de 35 à 4.

## Exercice 3

Cette Exercice 3 va nous permettre de comparer des plans d'exécution Oracle et de donner un avis critique dessus.

### Partie 1

Soit le schéma relationnel suivant :

```
CREATE TABLE Artiste (
    ID_artiste VARCHAR(4),
    Nom VARCHAR(32),
    Adresse VARCHAR(32)
);

CREATE TABLE Film (
```

```

ID_film VARCHAR(4),
Titre VARCHAR(32),
Annee VARCHAR(4),
ID_realisateur VARCHAR(4)
);

```

```

CREATE TABLE Joue (
ID_artiste VARCHAR(4),
ID_film VARCHAR(4)
);

```

## Question 1

On nous demande de créer la requête SQL pour "Afficher le nom des acteurs et le titre des films où ils ont joués".

```

SELECT Artiste.Nom, Film.Titre
FROM Artiste
JOIN Joue ON Artiste.ID_artiste = Joue.ID_artiste
JOIN Film ON Joue.ID_film = Film.ID_film;

```

## Question 2

Son expression en algèbre relationnelle (PEL) est la suivante :

$$\pi_{\{\text{Nom}, \text{Titre}\}} (\text{Artiste} \bowtie_{\{\text{Artiste.ID\_artiste} = \text{Joue.ID\_artiste}\}} \text{Joue} \bowtie_{\{\text{Joue.ID\_film} = \text{Film.ID\_film}\}} \text{Film})$$

## Question 3

Cette question est la plus intéressante car elle nous demande d'analyser le plan d'exécution Oracle suivant :

1. Plan 1 -> il n'existe que deux index, un sur FILM(ID-realisateur), et un sur ARTISTE(ID- artiste)

```

0 SELECT STATEMENT
1 MERGE JOIN
2 SORT JOIN
3 NESTED LOOPS
4 TABLE ACCESS FULL JOUE
5 TABLE ACCESS BY ROWID ARTISTE
6 INDEX UNIQUE SCAN ARTISTE_IDX
7 SORT JOIN
8 TABLE ACCESS FULL Film

```

```

graph TD
    subgraph Final_Step
        A[0: SELECT STATEMENT]
    
```

```

end

subgraph Operation_Principale
B[1: MERGE JOIN]
end

subgraph Branche_Gauche_Artiste_Joue
C[2: SORT JOIN]
D[3: NESTED LOOPS]
E[4: TABLE ACCESS FULL - JOUE]
F[5: TABLE ACCESS BY ROWID - ARTISTE]
G[6: INDEX UNIQUE SCAN - ARTISTE_IDX]
end

subgraph Branche_Droite_Film
H[7: SORT JOIN]
I[8: TABLE ACCESS FULL - FILM]
end

A --> B
B -- 1er flux trié --> C
B -- 2ème flux trié --> H
C --> D
H --> I

D -- Table pilote --> E
D -- Recherche correspondance --> F
F --> G

```

### 1. Plan 2 -> un index sur FILM(ID –Film), et un sur JOUE(ID –Artiste)

```

0 SELECT STATEMENT
1 NESTED LOOPS
2 NESTED LOOPS
3 TABLE ACCESS FULL ARTISTE
4 TABLE ACCESS BY ROWID JOUE
5 INDEX RANGE SCAN JOUE_ARTISTE
6 TABLE ACCESS BY ROWID FILM
7 INDEX UNIQUE SCAN FILM_IDX

```

### 3. Plan 3 -> un index sur FILM(ID –Film), et un sur JOUE(ID –Film)

```

0 SELECT STATEMENT
1 MERGE JOIN
2 SORT JOIN
3 NESTED LOOPS
4 TABLE ACCESS FULL JOUE
5 TABLE ACCESS BY ROWID FILM
6 INDEX UNIQUE SCAN FILM_IDX

```

7 SORT JOIN

8 TABLE ACCESS FULL ARTISTE